goophi - clustering

2022.08.24.

Table of contents

1	Introduction	1
2	Import sample data	1
3	K-means clustering	2
4	K-means clustering without hyperparameters	4
5	Visualize	5

1 Introduction

- 1) 본 문서는 goophi 패키지를 Shiny app에서 사용하는 것을 상정해 작성했습니다.
- 2) 본 문서의 케이스 스타일은 Camel case와 Snake case가 혼용되어 있습니다.
- Camel case : goophi의 함수명 및 파라미터명
- Snake case: 유저로부터 받는 입력, shiny app의 server에서 사용(될 것이라고 예상)하는 object명, snake case로 작성된 dependencies의 함수명 등

2 Import sample data

- 1) 전처리가 완료된 샘플데이터를 불러옵니다.
- NA가 없어야 함
- string value가 있는 열은 factor로 변환

- 한 열이 모두 같은 값으로 채워져 있을 경우 제외해야 함
- Date type column이 없어야 함
- Outcome 변수는 classification의 경우 factor, regression의 경우 numeric이어야 함 (clustering은 outcome변수를 사용하지 않음)

```
506 obs. of 13 variables:
'data.frame':
        : num 18 0 0 0 0 0 12.5 12.5 12.5 12.5 ...
$ indus : num 2.31 7.07 7.07 2.18 2.18 2.18 7.87 7.87 7.87 7.87 ...
$ chas : num 1 1 1 1 1 1 1 1 1 1 ...
$ nox
        : num 0.538 0.469 0.469 0.458 0.458 0.458 0.524 0.524 0.524 0.524 ...
        : num 6.58 6.42 7.18 7 7.15 ...
$ rm
        : num 65.2 78.9 61.1 45.8 54.2 58.7 66.6 96.1 100 85.9 ...
$ age
        : num 4.09 4.97 4.97 6.06 6.06 ...
$ dis
$ rad
        : int 1223335555...
$ tax
      : int 296 242 242 222 222 222 311 311 311 311 ...
$ ptratio: num 15.3 17.8 17.8 18.7 18.7 18.7 15.2 15.2 15.2 15.2 ...
$ black : num 397 397 393 395 397 ...
$ lstat : num 4.98 9.14 4.03 2.94 5.33 ...
$ medv
         : num 24 21.6 34.7 33.4 36.2 28.7 22.9 27.1 16.5 18.9 ...
```

3 K-means clustering

```
# user input
max_k <- "15" # k = 2:max_k, <= number of columns
n_start <- "25" # attempts 25 initial configurations, <= 175
iter_max <- "10" # <= 5000
n_boot <- "100" # Used only for determining the number of clusters using gap statistic
algorithm = "Hartigan-Wong" ## "Hartigan-Wong", "Lloyd", "Forgy", "MacQueen"
select_optimal <- "silhouette" # "silhouette", "gap_stat" // there's no mathematical definit</pre>
```

K-means clustering with 2 clusters of sizes 137, 369

Cluster means:

```
zn indus chas nox rm age dis rad
1 0.00000 18.451825 1.058394 0.6701022 6.006212 89.96788 2.054470 23.270073
2 15.58266 8.420894 1.073171 0.5118474 6.388005 60.63225 4.441272 4.455285
tax ptratio black lstat medv
1 667.6423 20.19635 291.0391 18.67453 16.27226
2 311.9268 17.80921 381.0426 10.41745 24.85718
```

Clustering vector:

Within cluster sum of squares by cluster:

4 K-means clustering without hyperparameters

```
# K-means clustering
km_model <- goophi::kMeansClustering(data = cleaned_data)
km_model$result</pre>
```

K-means clustering with 2 clusters of sizes 137, 369

```
Cluster means:
```

```
zn indus chas nox rm age dis rad
1 0.00000 18.451825 1.058394 0.6701022 6.006212 89.96788 2.054470 23.270073
2 15.58266 8.420894 1.073171 0.5118474 6.388005 60.63225 4.441272 4.455285
tax ptratio black lstat medv
1 667.6423 20.19635 291.0391 18.67453 16.27226
2 311.9268 17.80921 381.0426 10.41745 24.85718
```

Clustering vector:

Within cluster sum of squares by cluster:
[1] 2873179 2868624
(between_SS / total_SS = 70.3 %)


Available components:

[1] "cluster" "centers" "totss" "withinss" "tot.withinss"


[6] "betweenss" "size" "iter" "ifault"

5 Visualize

km_model\$elbowPlot



km_model\$optimalK



km_model\$clustVis

