# stove - regression

## 5/2/23

## Table of contents

1	Introduction	1
2	Import sample data	2
3	Data Setup Tab	3
4	Modeling Tab	3
	4.1 Linear Regression	4
	4.2 K Nearest Neighbor	5
	4.3 Decision Tree	6
	4.4 Random Forest	6
	4.5 XGBoost	7
	4.6 lightGBM	8
	4.7 MLP	9
5	Sources for report	10
	5.1 Regression plot (actual vs predicted)	10
	5.2 Evaluation metrics	11
	5.3 RMSF plot	12

## 1 Introduction

- 1) 본 문서는 stove 패키지를 Shiny app에서 사용하는 것을 상정해 작성했습니다.
- 2) stove 패키지의 code 스타일은 OHDSI code style을 따랐습니다.

3) 본 문서에서 사용하는 global preprocessing / local preprocesing은 다음을 의미합니다. 다른 값이나 데이터의 분산 등을 사용하지 않는 전처리: 중복값 제거, 원-핫 인코딩, 피처 선택 등 -> global preprocessing 다른 값이나 데이터의 분산 등을 사용하는 전처리: Imputation, Scaling, Oversampling 등 -> local preprocessing

## 2 Import sample data

- 1) global preprocessing이 완료된 샘플데이터를 불러옵니다.
- NA가 없어야 함
- string value가 있는 열은 factor로 변환
- 한 열이 모두 같은 값으로 채워져 있을 경우 제외해야 함
- Date type column이 없어야 함
- Outcome 변수는 classification의 경우 factor, regression의 경우 numeric이어야 함 (clustering은 outcome변수를 사용하지 않음)
- 2) 본 문서에서 사용한 혈액검사 샘플데이터의 정보는 아래와 같습니다.
- SEX : 성별(남성:1, 여성:2)
- AGE\_G : 연령(그룹)
- HGB : 혈색소
- TCHOL: 총콜레스테롤
- TG : 중성지방
- HDL : HDL 콜레스테롤
- ANE : 빈혈 진료여부(있음:1, 없음:0)
- IHD : 허혈심장질환 진료여부(있음:1, 없음:0) • STK : 뇌혈관질환 진료여부(있음:1, 없음:0)
- 3) N수가 너무 크면 알고리즘에 따라 모델링 시간무 길어질 수 있습니다.

```
# remotes::install_github("statgarten/datatoys")
library(stove)
library(datatoys)
library(dplyr)
```

Warning: package 'dplyr' was built under R version 4.2.3

```
set.seed(1234)
cleaned_data <- datatoys::bloodTest
cleaned_data <- cleaned_data %>%
  mutate_at(vars(SEX, ANE, IHD, STK), factor) %>%
  sample_n(1000)
```

## 3 Data Setup Tab

User Input	description
target_var	목적 변수
train_set_ratio	전체 데이터 중 train set의 비율 (range: 0.0 - 1.0)

- 1) User input을 다음과 같이 받습니다.
- formula는 user가 target\_var를 입력할 때 함께 생성되도록 함

```
target_var <- "TG"
train_set_ratio <- 0.7
seed <- 1234
formula <- paste0(target_var, " ~ .")</pre>
```

2) Train-test split 작업이 완료된 Object를 저장하고, Train set을 보여줍니다.

3) train set에 적용할 local preprocessing 정보를 담은 recipe를 생성합니다

## 4 Modeling Tab

User Input	description	
algo	사용자정의 알고리즘명	

User Input	description		
engine	 알고리즘 구현 engine 선택		
mode	mode 선택(분류/회귀)		
trainingData	훈련데이터 셋		
splitedData	분할정보가 담긴 전체 데이터 셋		
formula	Target 변수와 Feature 변수를 정의한 formula		
rec	교차 검증에서 각 fold에 적용할 local preprocessing 정보를 담은 recipe		
V	교차검증시 훈련셋을 몇 번 분할할 것인지 입력		
gridNum	각 하이퍼파라미터 별로 몇 개의 그리드를 할당해 베이지안 최적화를할지		
	설정 (ex. 모델의 하이퍼파라미터가 3개, gridNum이 5일 때,		
	하이퍼파라미터 최적화를 위한 그리드는 3*5=15개)		
iter	베이지안 최적화 시 반복 횟수		
metric	Best performance에 대한 평가지표 선택		
seed	결과 재현을 위한 시드값 설정		

모델 object를 저장할 빈 리스트를 생성합니다.

```
models_list <- list()
tuned_results_list <- list()</pre>
```

### 4.1 Linear Regression

```
# User input
mode <- "regression"
algo <- "linearRegression"
engine <- "glmnet" # glmnet (default)
v <- 2
metric <- "rmse" # rmse (default), rsq
gridNum <- 5
iter <- 10
seed <- 1234

# Modeling
finalized <- stove::linearRegression(
    algo = algo,
    engine = engine,
    mode = mode,
    trainingData = data_train,
    splitedData = data_split,</pre>
```

```
formula = formula,
  rec = rec,
  v = v,
  gridNum = gridNum,
  iter = iter,
  metric = metric,
  seed = seed
)
# Add the model to models_list
models_list[[paste0(algo, "_", engine)]] <- finalized$finalized$finalFittedModel
tuned_results_list[[paste0(algo, "_", engine)]] <- finalized$bayes_opt_result</pre>
```

#### 4.2 K Nearest Neighbor

```
mode <- "regression"</pre>
algo <- "KNN"</pre>
engine <- "kknn" # kknn (defualt)</pre>
metric <- "rmse" # rmse (default), rsq</pre>
gridNum <- 5
iter <- 10
seed <- 1234
finalized <- stove::KNN(</pre>
 algo = algo,
 engine = engine,
 mode = mode,
  trainingData = data_train,
  splitedData = data_split,
  formula = formula,
  rec = rec,
  v = v,
  gridNum = gridNum,
  iter = iter,
  metric = metric,
  seed = seed
```

```
models_list[[paste0(algo, "_", engine)]] <- finalized$finalized$finalFittedModel
tuned_results_list[[paste0(algo, "_", engine)]] <- finalized$bayes_opt_result</pre>
```

#### 4.3 Decision Tree

```
mode <- "regression"</pre>
algo <- "decisionTree"</pre>
engine <- "rpart" # rpart (default), partykit</pre>
v <- 2
metric <- "rmse" # rmse (default), rsq</pre>
gridNum <- 5
iter <- 10
seed <- 1234
finalized <- stove::decisionTree(</pre>
  algo = algo,
 engine = engine,
 mode = mode,
 trainingData = data_train,
  splitedData = data_split,
  formula = formula,
 rec = rec,
  v = v,
  gridNum = gridNum,
  iter = iter,
  metric = metric,
  seed = seed
models_list[[paste0(algo, "_", engine)]] <- finalized$finalized$finalFittedModel</pre>
tuned_results_list[[paste0(algo, "_", engine)]] <- finalized$bayes_opt_result</pre>
```

#### 4.4 Random Forest

```
mode <- "regression"</pre>
algo <- "randomForest"</pre>
engine <- "ranger" # ranger (default), randomForest, partykit</pre>
v <- 2
metric <- "rmse" # rmse (default), rsq</pre>
gridNum <- 5
iter <- 10
seed <- 1234
finalized <- stove::randomForest(</pre>
  algo = algo,
 engine = engine,
  mode = mode,
  trainingData = data_train,
  splitedData = data_split,
 formula = formula,
  rec = rec,
  v = v,
  gridNum = gridNum,
  iter = iter,
  metric = metric,
  seed = seed
models_list[[paste0(algo, "_", engine)]] <- finalized$finalized$finalFittedModel</pre>
tuned_results_list[[paste0(algo, "_", engine)]] <- finalized$bayes_opt_result</pre>
```

#### 4.5 XGBoost

```
# User input
mode <- "regression"
algo <- "XGBoost"
engine <- "xgboost" # xgboost
v <- 2
metric <- "rmse" # rmse (default), rsq
gridNum <- 5
iter <- 10
seed <- 1234</pre>
```

```
# Modeling
finalized <- stove::xgBoost(
    algo = algo,
    engine = engine,
    mode = mode,
    trainingData = data_train,
    splitedData = data_split,
    formula = formula,
    rec = rec,
    v = v,
    gridNum = gridNum,
    iter = iter,
    metric = metric,
    seed = seed
)
# Add the model to models_list
models_list[[paste0(algo, "_", engine)]] <- finalized$finalFittedModel
tuned_results_list[[paste0(algo, "_", engine)]] <- finalized$bayes_opt_result</pre>
```

#### 4.6 lightGBM

```
# User input
mode <- "regression"
algo <- "lightGBM"
engine <- "lightgbm" # lightgbm
v <- 2
metric <- "rmse" # rmse (default), rsq
gridNum <- 5
iter <- 10
seed <- 1234

# Modeling
finalized <- stove::lightGbm(
    algo = algo,
    engine = engine,
    mode = mode,
    trainingData = data_train,
    splitedData = data_split,
    formula = formula,</pre>
```

```
rec = rec,
v = v,
gridNum = gridNum,
iter = iter,
metric = metric,
seed = seed
)
# Add the model to models_list
models_list[[paste0(algo, "_", engine)]] <- finalized$finalized$finalFittedModel
tuned_results_list[[paste0(algo, "_", engine)]] <- finalized$bayes_opt_result</pre>
```

#### 4.7 MLP


```
mode <- "regression"</pre>
algo <- "MLP"</pre>
engine <- "nnet" # nnet</pre>
metric <- "rmse" # rmse (default), rsq
gridNum <- 5
iter <- 10
seed <- 1234
finalized <- stove::MLP(</pre>
  algo = algo,
 engine = engine,
 mode = mode,
 trainingData = data_train,
  splitedData = data_split,
  formula = formula,
 rec = rec,
  v = v,
  gridNum = gridNum,
  iter = iter,
  metric = metric,
  seed = seed
```

```
models_list[[paste0(algo, "_", engine)]] <- finalized$finalized$finalFittedModel
tuned_results_list[[paste0(algo, "_", engine)]] <- finalized$bayes_opt_result</pre>
```

## **5** Sources for report

#### 5.1 Regression plot (actual vs predicted)

유저가 선택한 모델의 confusion matrix 출력 리스트 내 모델의 이름은 {algo}\_{engine}의 형태로 저장되어 있음



## 5.2 Evaluation metrics

• 모델 성능 비교를 위한 표 출력


```
evalMet <- stove::evalMetricsR(models_list, target_var)
knitr::kable(evalMet)</pre>
```

	RMSE	RSQ	MAE	MASE	RPD
linearRegression_glmnet	75.879	0.309	51.428	0.568	1.204
KNN_kknn	78.338	0.263	52.434	0.579	1.166
decisionTree_rpart	79.390	0.255	55.598	0.614	1.151
randomForest_ranger	76.129	0.310	52.189	0.576	1.200
XGBoost_xgboost	73.989	0.344	50.180	0.554	1.235
lightGBM_lightgbm	76.819	0.297	51.723	0.571	1.189
MLP_nnet	91.223	0.005	62.893	0.695	1.001

## 5.3 RMSE plot

\$rmse\_plot

## **RMSE Comparison**



#### \$rmse\_summary

# A tibble: 7 x 5

	model	mean_rmse	rmse_se	lower_bound	upper_bound
	<chr></chr>	<dbl></dbl>	<dbl></dbl>	<dbl></dbl>	<dbl></dbl>
1	KNN_kknn	90.0	1.84	86.4	93.6
2	MLP_nnet	85.8	0.799	84.3	87.4
3	XGBoost_xgboost	82.2	0.817	80.6	83.8
4	decisionTree_rpart	89.0	2.30	84.5	93.5
5	lightGBM_lightgbm	80.9	0.356	80.2	81.6
6	linearRegression_glmnet	78.8	0.00844	78.8	78.8
7	randomForest ranger	80.3	0.255	79.8	80.8

#### \$model\_name

- [1] "linearRegression\_glmnet" "KNN\_kknn"
- [5] "XGBoost\_xgboost" "lightGBM\_lightgbm"
- [7] "MLP\_nnet"